


Диаграмма развёртывания RAG-системы



1. Пользователь работает через веб-интерфейс или REST API.
2. API и worker используют PostgreSQL, Qdrant и файловое хранилище.
3. Worker вызывает Docling, локальный TEI и локальный vLLM при local-профилях.
4. При cloud-профилях используются внешние LLM и embedding API.
5. API и worker отправляют GELF-логи в Graylog.
6. PostgreSQL, Qdrant, MinIO и файловое хранилище сохраняют данные в volumes.
7. AI-сервисы используют volume hf\_cache для моделей.
8. Graylog хранит конфигурацию и индекс логов в отдельных volumes.

Профиль по умолчанию:

LLM=cloud, EMBEDDING=cloud,  
DOCLING=local, POSTGRES=local,  
QDRANT=local, OBJECT\_STORAGE=filesystem,  
GRAYLOG=local.